Bergische Universität Wuppertal
Wissenschaftliches Rechnen und Hochleistungsrechnen
Dr. Marcel Schweitzer

Bachelor-Seminar „Top 10 Algorithms in Data Mining“

AdaBoost

Marius Graf

06.12.2023

Inhalt

Inhalt

Was ist Data Mining?

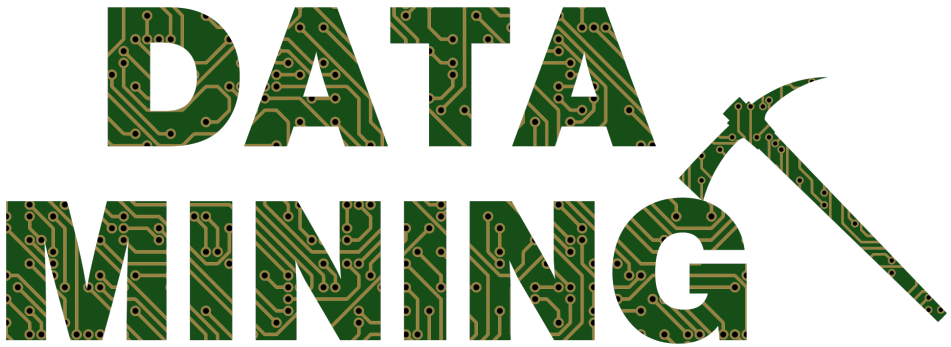

- **Analysiert** große Datenmengen, um Muster und Zusammenhänge zu erkennen.
- Nutzt dabei Methoden aus der **Statistik**, dem **Machine Learning** und Datenbanktechnologien.
- Spielt zentrale Rolle in der Forschung und Industrie, um Erkenntnisse zu gewinnen und Entscheidungen zu unterstützen.

Was ist Data Mining?

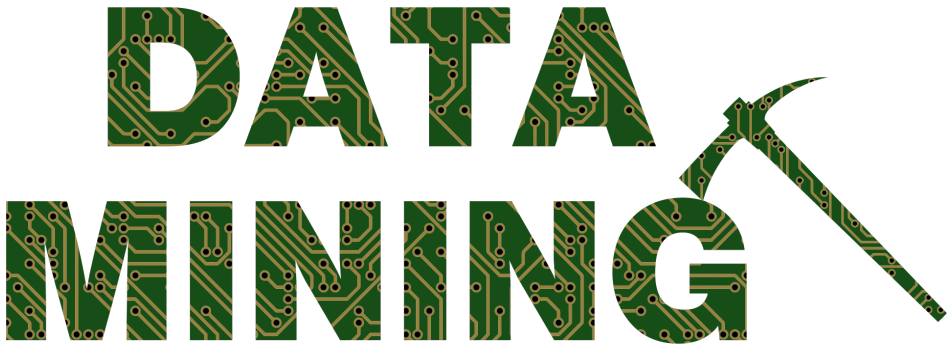

- **Analysiert** große Datenmengen, um Muster und Zusammenhänge zu erkennen.
- Nutzt dabei Methoden aus der **Statistik**, dem **Machine Learning** und Datenbanktechnologien.
- Spielt zentrale Rolle in der Forschung und Industrie, um Erkenntnisse zu gewinnen und Entscheidungen zu unterstützen.

Was ist Data Mining?

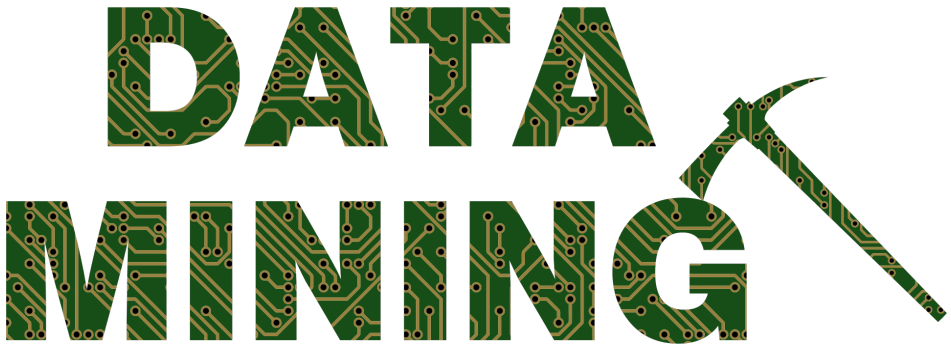

- **Analysiert** große Datenmengen, um Muster und Zusammenhänge zu erkennen.
- Nutzt dabei Methoden aus der **Statistik**, dem **Machine Learning** und Datenbanktechnologien.
- Spielt zentrale Rolle in der Forschung und Industrie, um Erkenntnisse zu gewinnen und Entscheidungen zu unterstützen.

Was sind Ensemble-Methoden?

- **Ensemble-Verfahren: Kombinieren** mehrere Modelle für präzisere Vorhersagen
- **Fehlerminimierung:** Reduzieren von **systematischen Fehlern** in Modellprognosen
- **Arten von Ensemble-Methoden:**
  - Bagging
  - Stacking
  - Boosting
- **AdaBoost gehört zu den Boosting-Verfahren**

Was sind Ensemble-Methoden?

- **Ensemble-Verfahren: Kombinieren** mehrere Modelle für präzisere Vorhersagen
- **Fehlerminimierung:** Reduzieren von **systematischen Fehlern** in Modellprognosen
- **Arten von Ensemble-Methoden:**
  - Bagging
  - Stacking
  - Boosting
- **AdaBoost gehört zu den Boosting-Verfahren**

Was sind Ensemble-Methoden?

- **Ensemble-Verfahren: Kombinieren** mehrere Modelle für präzisere Vorhersagen
- **Fehlerminimierung:** Reduzieren von **systematischen Fehlern** in Modellprognosen
- **Arten von Ensemble-Methoden:**
  - Bagging
  - Stacking
  - Boosting
- **AdaBoost gehört zu den Boosting-Verfahren**

Was sind Ensemble-Methoden?

- **Ensemble-Verfahren: Kombinieren** mehrere Modelle für präzisere Vorhersagen
- **Fehlerminimierung:** Reduzieren von **systematischen Fehlern** in Modellprognosen
- **Arten von Ensemble-Methoden:**
  - Bagging
  - Stacking
  - Boosting
- **AdaBoost gehört zu den Boosting-Verfahren**

Inhalt

Die Grundidee

- Boosting kombiniert **schwache Lerner** zu einem **starken Gesamtmodell**
- **Schwacher Lerner:** Modell, das nur **geringfügig besser** ist als **zufälliges Raten**
- **Passe Gewichtung** der Trainingsdaten iterativ **an**, damit neue Modelle die **Fehler der Vorgänger korrigieren**
- $\rightsquigarrow$ verringerter **Bias, bessere Vorhersagegenauigkeit** für schwer klassifizierbare Beispiele

Die Grundidee

- Boosting kombiniert **schwache Lerner** zu einem **starken Gesamtmodell**
- **Schwacher Lerner:** Modell, das nur **geringfügig besser** ist als **zufälliges Raten**
- **Passe Gewichtung** der Trainingsdaten iterativ **an**, damit neue Modelle die **Fehler der Vorgänger korrigieren**
- $\rightsquigarrow$ verringerter **Bias, bessere Vorhersagegenauigkeit** für schwer klassifizierbare Beispiele

Die Grundidee

- Boosting kombiniert **schwache Lerner** zu einem **starken Gesamtmodell**
- **Schwacher Lerner:** Modell, das nur **geringfügig besser** ist als **zufälliges Raten**
- **Passe Gewichtung** der Trainingsdaten iterativ **an**, damit neue Modelle die **Fehler der Vorgänger korrigieren**
- $\rightsquigarrow$ verringerter **Bias, bessere Vorhersagegenauigkeit** für schwer klassifizierbare Beispiele

Die Grundidee

- Boosting kombiniert **schwache Lerner** zu einem **starken Gesamtmodell**
- **Schwacher Lerner:** Modell, das nur **geringfügig besser** ist als **zufälliges Raten**
- **Passe Gewichtung** der Trainingsdaten iterativ **an**, damit neue Modelle die **Fehler der Vorgänger korrigieren**
- $\rightsquigarrow$ verringerter **Bias, bessere Vorhersagegenauigkeit** für schwer klassifizierbare Beispiele

Veranschaulichung

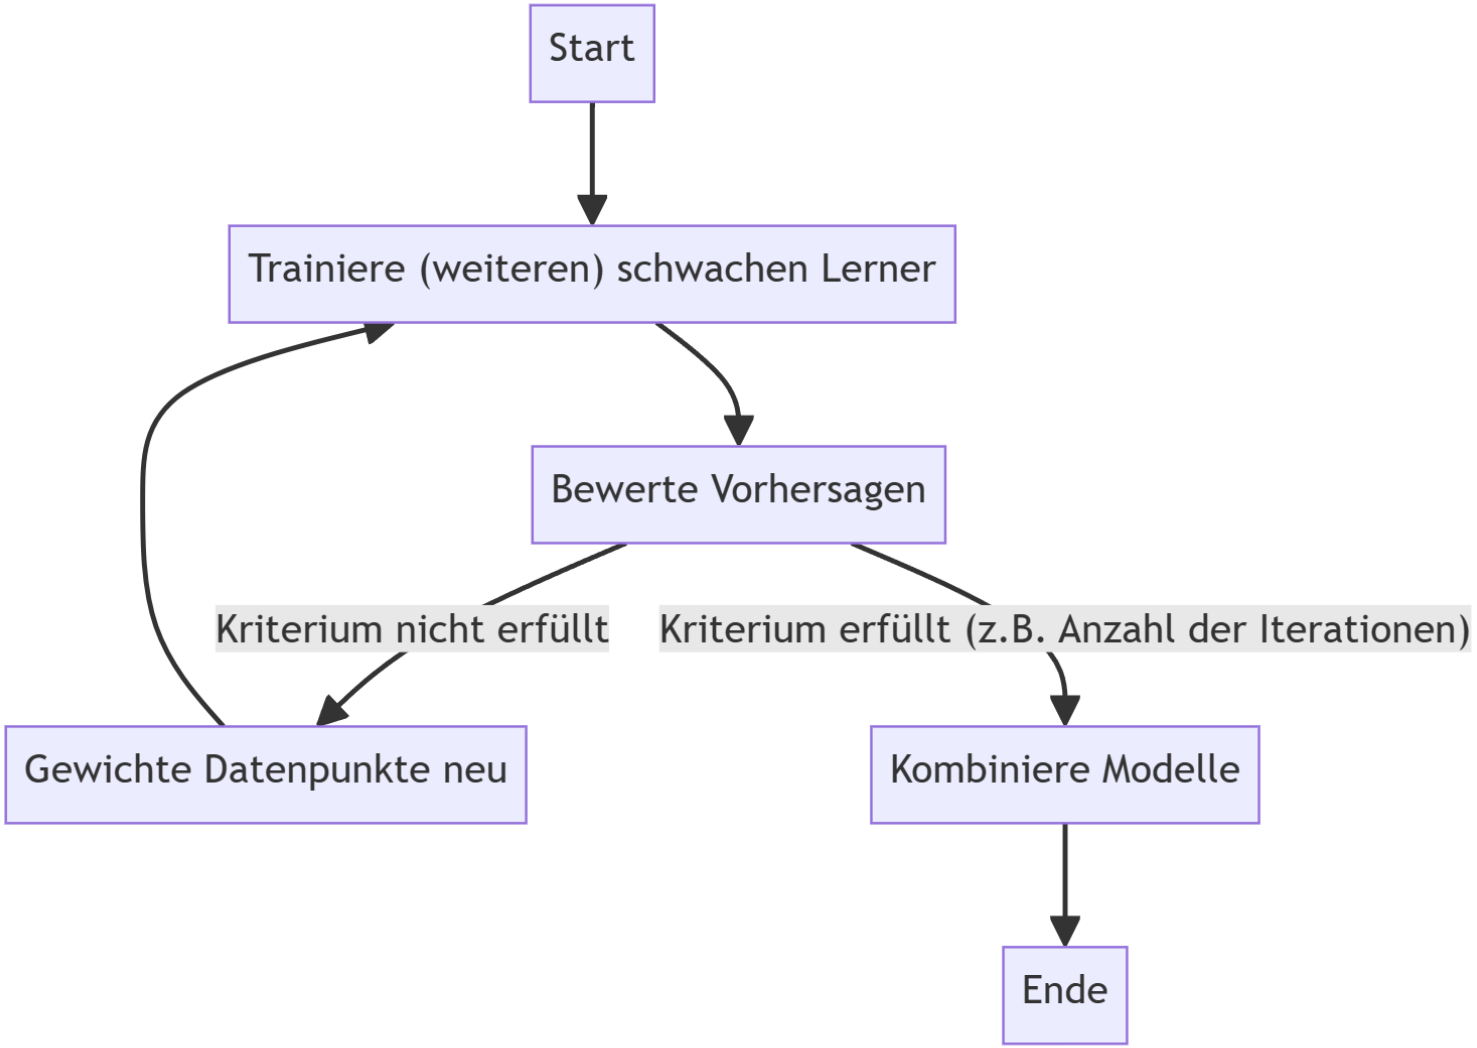

Beispiel

Vorhersage von Hauspreisen

- Wir möchten ein **Modell** entwickeln, das den **Preis von Häusern** basierend auf **verschiedenen Merkmalen** wie Größe, Lage, Anzahl der Zimmer und Baujahr **vorhersagt**.

Haus	**Größe** $[m^2]$	**Lage**	**Preis**
Haus 1	100	Zentrum	440.000€
Haus 2	150	Vorort	500.000€
Haus 3	80	Zentrum	400.000€
Haus 4	120	Ländlich	200.000€

Beispiel

Vorhersage von Hauspreisen

- **Einfaches Modell** (schwacher Lerner): Preisvorhersage nur anhand von **Größe**
- Tatsächlich spielen auch **andere Faktoren** (z.B. Lage) eine Rolle
- $\rightsquigarrow$ **Bias** des schwachen Lerners:
  - Preis von Häusern in guter Lage wird **unterschätzt**
  - Preis von Häusern in schlechter Lage wird **überschätzt**

Beispiel

Vorhersage von Hauspreisen

- **Einfaches Modell** (schwacher Lerner): Preisvorhersage nur anhand von **Größe**
- Tatsächlich spielen auch **andere Faktoren** (z.B. Lage) eine Rolle
- $\rightsquigarrow$ **Bias** des schwachen Lerners:
  - Preis von Häusern in guter Lage wird **unterschätzt**
  - Preis von Häusern in schlechter Lage wird **überschätzt**

Beispiel

Vorhersage von Hauspreisen

- **Einfaches Modell** (schwacher Lerner): Preisvorhersage nur anhand von **Größe**
- Tatsächlich spielen auch **andere Faktoren** (z.B. Lage) eine Rolle
- $\rightsquigarrow$ **Bias** des schwachen Lerners:
  - Preis von Häusern in guter Lage wird **unterschätzt**
  - Preis von Häusern in schlechter Lage wird **überschätzt**

Beispiel

Vorhersage von Hauspreisen

- **Boosting:** Passe iterativ Gewicht der Datenpunkte so an, dass nächstes Modell verstärkt die schlecht vorhergesagten Fälle beachtet

P = Vorhersage, W = Gewichtung

Haus	**Größe** $[m^2]$	**Lage**	**Preis**
Haus 1	100	Zentrum	440.000€
Haus 2	150	Vorort	500.000€
Haus 3	80	Zentrum	400.000€
Haus 4	120	Ländlich	200.000€

Haus	**P(1)**	**W(1)**	**P(2)**	**W(2)**	**P(3)**
Haus 1	450.000€	0.1307	445.000€	0.1192	443.000€
Haus 2	350.000€	0.5299	495.000€	0.4833	501.000€
Haus 3	380.000€	0.1444	430.000€	0.1691	410.000€
Haus 4	250.000€	0.1950	230.000€	0.2283	205.000€

Inhalt

Einführung

- „Adaptive Boosting“
- Entwickelt in den 1990ern von Freund und Schapire, einflussreiches Verfahren für **binäre Klassifikation**
- Berechnung eines **Lernkoeffizienten** zur Gewichtung eines Lerners im Ensemble
- Nutzung des Lernkoeffizienten zur **exponentiellen Neugewichtung** falsch klassifizierter Datenpunkte

Einführung

- „Adaptive Boosting“
- Entwickelt in den 1990ern von Freund und Schapire, einflussreiches Verfahren für **binäre Klassifikation**
- Berechnung eines **Lernkoeffizienten** zur Gewichtung eines Lerners im Ensemble
- Nutzung des Lernkoeffizienten zur **exponentiellen Neugewichtung** falsch klassifizierter Datenpunkte

Einführung

- „Adaptive Boosting“
- Entwickelt in den 1990ern von Freund und Schapire, einflussreiches Verfahren für **binäre Klassifikation**
- Berechnung eines **Lernkoeffizienten** zur Gewichtung eines Lerners im Ensemble
- Nutzung des Lernkoeffizienten zur **exponentiellen Neugewichtung** falsch klassifizierter Datenpunkte

Einführung

- „Adaptive Boosting“
- Entwickelt in den 1990ern von Freund und Schapire, einflussreiches Verfahren für **binäre Klassifikation**
- Berechnung eines **Lernkoeffizienten** zur Gewichtung eines Lerners im Ensemble
- Nutzung des Lernkoeffizienten zur **exponentiellen Neugewichtung** falsch klassifizierter Datenpunkte

Vereinfachte Sicht auf den Algorithmus

Input: Datensatz, Lernalgorithmus
Initialisiere Gewichte des Datensatzes
for $t = 1$ **to** T **do**
    Trainiere schwache Lerner mit gewichtetem Datensatz
    Bestimme Fehler der Lerner
    Wähle schwachen Lerner mit geringstem Fehler
    Berechne Lernkoeffizienten
    Gewichte Datenpunkte neu
Output: Starker Lerner (Ensemble)

Notation

- $\mathcal{X}$: Menge der **Features**
- $\mathcal{Y}$: Menge der **Labels** ($\mathcal{Y} = \{-1, +1\}$ bei binärer Klassifikation)
- D : **Trainingdatensatz** der Form $D = \{(\boldsymbol{x}_i, y_i)\},\ i = 1, ..., m$
- Modell wird auf D durch **Lernalgorithmus** $\mathcal{L}$ (meistens *Decision Stump*) trainiert und gibt
- n **Hypothesen** $(h_j)_{j \in \mathcal{I}},\ h_j : X \to \mathcal{Y},\ h_j(\boldsymbol{x}) = y$ mit $\mathcal{I} = \{1, ..., n\}$ zurück
- Anzahl der **Trainingsiterationen** T
- bei jeder Iteration wird D um **Gewichte**

$$w_i^{(t)}$$

mit $i = 1, \ldots, m$ und $t = 1, \ldots, T$ erweitert

Notation

- $\mathcal{X}$: Menge der **Features**
- $\mathcal{Y}$: Menge der **Labels** ($\mathcal{Y} = \{-1, +1\}$ bei binärer Klassifikation)
- D : **Trainingdatensatz** der Form $D = \{(\boldsymbol{x}_i, y_i)\},\ i = 1, ..., m$
- Modell wird auf D durch **Lernalgorithmus** $\mathcal{L}$ (meistens *Decision Stump*) trainiert und gibt
- n **Hypothesen** $(h_j)_{j \in \mathcal{I}},\ h_j : X \to \mathcal{Y},\ h_j(\boldsymbol{x}) = y$ mit $\mathcal{I} = \{1, ..., n\}$ zurück
- Anzahl der **Trainingsiterationen** T
- bei jeder Iteration wird D um **Gewichte**

$$w_i^{(t)}$$

mit $i = 1, \ldots, m$ und $t = 1, \ldots, T$ erweitert

Notation

- $\mathcal{X}$: Menge der **Features**
- $\mathcal{Y}$: Menge der **Labels** ($\mathcal{Y} = \{-1, +1\}$ bei binärer Klassifikation)
- D : **Trainingdatensatz** der Form $D = \{(\boldsymbol{x}_i, y_i)\},\ i = 1, ..., m$
- Modell wird auf D durch **Lernalgorithmus** $\mathcal{L}$ (meistens *Decision Stump*) trainiert und gibt
- n **Hypothesen** $(h_j)_{j \in \mathcal{I}},\ h_j : X \to \mathcal{Y},\ h_j(\boldsymbol{x}) = y$ mit $\mathcal{I} = \{1, ..., n\}$ zurück
- Anzahl der **Trainingsiterationen** T
- bei jeder Iteration wird D um **Gewichte**

$$w_i^{(t)}$$

mit $i = 1, \ldots, m$ und $t = 1, \ldots, T$ erweitert

Notation

- $\mathcal{X}$: Menge der **Features**
- $\mathcal{Y}$: Menge der **Labels** ($\mathcal{Y} = \{-1, +1\}$ bei binärer Klassifikation)
- D : **Trainingdatensatz** der Form $D = \{(\boldsymbol{x}_i, y_i)\},\ i = 1, ..., m$
- Modell wird auf D durch **Lernalgorithmus** $\mathcal{L}$ (meistens *Decision Stump*) trainiert und gibt
- n **Hypothesen** $(h_j)_{j \in \mathcal{I}},\ h_j : X \to \mathcal{Y},\ h_j(\boldsymbol{x}) = y$ mit $\mathcal{I} = \{1, ..., n\}$ zurück
- Anzahl der **Trainingsiterationen** T
- bei jeder Iteration wird D um **Gewichte**

$$w_i^{(t)}$$

mit $i = 1, \ldots, m$ und $t = 1, \ldots, T$ erweitert

Notation

- $\mathcal{X}$: Menge der **Features**
- $\mathcal{Y}$: Menge der **Labels** ($\mathcal{Y} = \{-1, +1\}$ bei binärer Klassifikation)
- D : **Trainingdatensatz** der Form $D = \{(\boldsymbol{x}_i, y_i)\},\ i = 1, ..., m$
- Modell wird auf D durch **Lernalgorithmus** $\mathcal{L}$ (meistens *Decision Stump*) trainiert und gibt
- n **Hypothesen** $(h_j)_{j \in \mathcal{I}},\ h_j : X \to \mathcal{Y},\ h_j(\boldsymbol{x}) = y$ mit $\mathcal{I} = \{1, ..., n\}$ zurück
- Anzahl der **Trainingsiterationen** T
- bei jeder Iteration wird D um **Gewichte**

$$w_i^{(t)}$$

mit $i = 1, \ldots, m$ und $t = 1, \ldots, T$ erweitert

Notation

- $\mathcal{X}$: Menge der **Features**
- $\mathcal{Y}$: Menge der **Labels** ($\mathcal{Y} = \{-1, +1\}$ bei binärer Klassifikation)
- D : **Trainingdatensatz** der Form $D = \{(\boldsymbol{x}_i, y_i)\},\ i = 1, ..., m$
- Modell wird auf D durch **Lernalgorithmus** $\mathcal{L}$ (meistens *Decision Stump*) trainiert und gibt
- n **Hypothesen** $(h_j)_{j \in \mathcal{I}},\ h_j : X \to \mathcal{Y},\ h_j(\boldsymbol{x}) = y$ mit $\mathcal{I} = \{1, ..., n\}$ zurück
- Anzahl der **Trainingsiterationen** T
- bei jeder Iteration wird D um **Gewichte**

$$w_i^{(t)}$$

mit $i = 1, \ldots, m$ und $t = 1, \ldots, T$ erweitert

Notation

- $\mathcal{X}$: Menge der **Features**
- $\mathcal{Y}$: Menge der **Labels** ($\mathcal{Y} = \{-1, +1\}$ bei binärer Klassifikation)
- D : **Trainingdatensatz** der Form $D = \{(\boldsymbol{x}_i, y_i)\},\ i = 1, ..., m$
- Modell wird auf D durch **Lernalgorithmus** $\mathcal{L}$ (meistens *Decision Stump*) trainiert und gibt
- n **Hypothesen** $(h_j)_{j \in \mathcal{I}},\ h_j : X \to \mathcal{Y},\ h_j(\boldsymbol{x}) = y$ mit $\mathcal{I} = \{1, ..., n\}$ zurück
- Anzahl der **Trainingsiterationen** T
- bei jeder Iteration wird D um **Gewichte**

$$w_i^{(t)}$$

mit $i = 1, \ldots, m$ und $t = 1, \ldots, T$ erweitert

Initialisierung der Gewichte

- Zu Beginn sind die Gewichte gleich verteilt

$$w_i^{(1)} = \frac{1}{m}, \; i = 1, \ldots, m$$

- Die Summe der Gewichte ist stets 1

$$\sum_{i=1}^{m} w_i^{(t)} = 1 \quad \forall t = 1, \ldots, T$$

Initialisierung der Gewichte

- Zu Beginn sind die Gewichte gleich verteilt

$$w_i^{(1)} = \frac{1}{m}, \; i = 1, \ldots, m$$

- Die Summe der Gewichte ist stets 1

$$\sum_{i=1}^{m} w_i^{(t)} = 1 \quad \forall t = 1, \ldots, T$$

Training der schwachen Lerner

- **Trainiere** pro Iteration n **schwache Lerner** (für jedes Feature zwei, je mit umgekehrter Polarität)

$$(h_j)_{j \in \mathcal{I}} = \mathcal{L}(D, w^{(t)})$$

mit $w^{(t)}$ als Gewichte der t-ten Iteration

- Ziel: gewichteten **Fehler minimieren**

$$\varepsilon_j = \sum_{i=1}^{m} w_i^{(t)} \cdot I\left(y_i \neq h_j\left(\boldsymbol{x}_i\right)\right), \; j = 1, \ldots, n$$

Wähle Lerner h_j aus der Folge mit **geringstem Fehler** ε_j als h_t

- Dabei bezeichntet I die **Indikatorfunktion**

$$I(A) = \begin{cases} 1, & \text{wenn } A \\ 0, & \text{sonst.} \end{cases}$$

Training der schwachen Lerner

- **Trainiere** pro Iteration n **schwache Lerner** (für jedes Feature zwei, je mit umgekehrter Polarität)

$$(h_j)_{j \in \mathcal{I}} = \mathcal{L}(D, w^{(t)})$$

mit $w^{(t)}$ als Gewichte der t-ten Iteration

- Ziel: gewichteten **Fehler minimieren**

$$\varepsilon_j = \sum_{i=1}^{m} w_i^{(t)} \cdot I\left(y_i \neq h_j\left(\boldsymbol{x}_i\right)\right), \; j = 1, \ldots, n$$

Wähle Lerner h_j aus der Folge mit **geringstem Fehler** ε_j als h_t

- Dabei bezeichntet I die **Indikatorfunktion**

$$I(A) = \begin{cases} 1, & \text{wenn } A \\ 0, & \text{sonst.} \end{cases}$$

Training der schwachen Lerner

- **Trainiere** pro Iteration n **schwache Lerner** (für jedes Feature zwei, je mit umgekehrter Polarität)

$$(h_j)_{j \in \mathcal{I}} = \mathcal{L}(D, w^{(t)})$$

mit $w^{(t)}$ als Gewichte der t-ten Iteration

- Ziel: gewichteten **Fehler minimieren**

$$\varepsilon_j = \sum_{i=1}^{m} w_i^{(t)} \cdot I\left(y_i \neq h_j\left(\boldsymbol{x}_i\right)\right), \; j = 1, \ldots, n$$

Wähle Lerner h_j aus der Folge mit **geringstem Fehler** ε_j als h_t

- Dabei bezeichntet I die **Indikatorfunktion**

$$I(A) = \begin{cases} 1, & \text{wenn } A \\ 0, & \text{sonst.} \end{cases}$$

Berechnung des Lernkoeffizienten

- Exponentieller Verlust

$$L(h_t) = \sum_{i=1}^{m} w_i^{(t)} e^{-y_i h_t(x_i)}$$

- Herleitung: führe Lernkoeffizienten α_t ein

$$L(h_t) = \sum_{i=1}^{m} w_i^{(t)} e^{-\alpha_t y_i h_t(x_i)}$$

Berechnung des Lernkoeffizienten

- Exponentieller Verlust

$$L(h_t) = \sum_{i=1}^{m} w_i^{(t)} e^{-y_i h_t(x_i)}$$

- Herleitung: führe Lernkoeffizienten α_t ein

$$L(h_t) = \sum_{i=1}^{m} w_i^{(t)} e^{-\alpha_t y_i h_t(x_i)}$$

Berechnung des Lernkoeffizienten

$$y_i = h_t(x_i) \implies y_i h_t(x_i) = 1$$

$$\rightsquigarrow \text{ Beitrag zum Verlust: } w_i^{(t)} e^{-\alpha_t}$$

$$y_i \neq h_t(x_i) \implies y_i h_t(x_i) = -1$$

$$\rightsquigarrow \text{ Beitrag zum Verlust: } w_i^{(t)} e^{\alpha_t}$$

- Minimieren von $L(h_t)$:

$$L(h_t) = \sum_{y_i = h_t(x_i)} w_i^{(t)} e^{-\alpha_t} + \sum_{y_i \neq h_t(x_i)} w_i^{(t)} e^{\alpha_t}$$

$$\frac{dL(h_t)}{d\alpha_t} = -e^{-\alpha_t} \sum_{y_i = h_t(x_i)} w_i^{(t)} + e^{\alpha_t} \sum_{y_i \neq h_t(x_i)} w_i^{(t)} = 0$$

Berechnung des Lernkoeffizienten

$$y_i = h_t(x_i) \implies y_i h_t(x_i) = 1$$
$$\rightsquigarrow \text{ Beitrag zum Verlust: } w_i^{(t)} e^{-\alpha_t}$$
$$y_i \neq h_t(x_i) \implies y_i h_t(x_i) = -1$$
$$\rightsquigarrow \text{ Beitrag zum Verlust: } w_i^{(t)} e^{\alpha_t}$$

- Minimieren von $L(h_t)$:

$$L(h_t) = \sum_{y_i = h_t(x_i)} w_i^{(t)} e^{-\alpha_t} + \sum_{y_i \neq h_t(x_i)} w_i^{(t)} e^{\alpha_t}$$

$$\frac{dL(h_t)}{d\alpha_t} = -e^{-\alpha_t} \sum_{y_i = h_t(x_i)} w_i^{(t)} + e^{\alpha_t} \sum_{y_i \neq h_t(x_i)} w_i^{(t)} = 0$$

Berechnung des Lernkoeffizienten

$$y_i = h_t(x_i) \implies y_i h_t(x_i) = 1$$

$$\rightsquigarrow \text{ Beitrag zum Verlust: } w_i^{(t)} e^{-\alpha_t}$$

$$y_i \neq h_t(x_i) \implies y_i h_t(x_i) = -1$$

$$\rightsquigarrow \text{ Beitrag zum Verlust: } w_i^{(t)} e^{\alpha_t}$$

- Minimieren von $L(h_t)$:

$$L(h_t) = \sum_{y_i = h_t(x_i)} w_i^{(t)} e^{-\alpha_t} + \sum_{y_i \neq h_t(x_i)} w_i^{(t)} e^{\alpha_t}$$

$$\frac{dL(h_t)}{d\alpha_t} = -e^{-\alpha_t} \sum_{y_i = h_t(x_i)} w_i^{(t)} + e^{\alpha_t} \sum_{y_i \neq h_t(x_i)} w_i^{(t)} = 0$$

Berechnung des Lernkoeffizienten

$$\Leftrightarrow e^{2\alpha_t} = \frac{\sum_{y_i = h_t(x_i)} w_i^{(t)}}{\sum_{y_i \neq h_t(x_i)} w_i^{(t)}}$$

$$\Leftrightarrow \alpha_t = \frac{1}{2} \ln \left(\frac{\sum_{y_i = h_t(x_i)} w_i^{(t)}}{\sum_{y_i \neq h_t(x_i)} w_i^{(t)}} \right)$$

- Da $\sum_{y_i \neq h_t(x_i)} w_i^{(t)} = \varepsilon_t$ und $\sum_{y_i = h_t(x_i)} w_i^{(t)} = 1 - \varepsilon_t$

$$\Longrightarrow \alpha_t = \frac{1}{2} \ln \left(\frac{1 - \varepsilon_t}{\varepsilon_t} \right)$$

Berechnung des Lernkoeffizienten

$$\Leftrightarrow e^{2\alpha_t} = \frac{\sum_{y_i = h_t(x_i)} w_i^{(t)}}{\sum_{y_i \neq h_t(x_i)} w_i^{(t)}}$$

$$\Leftrightarrow \alpha_t = \frac{1}{2} \ln \left(\frac{\sum_{y_i = h_t(x_i)} w_i^{(t)}}{\sum_{y_i \neq h_t(x_i)} w_i^{(t)}} \right)$$

- Da $\sum_{y_i \neq h_t(x_i)} w_i^{(t)} = \varepsilon_t$ und $\sum_{y_i = h_t(x_i)} w_i^{(t)} = 1 - \varepsilon_t$

$$\Longrightarrow \alpha_t = \frac{1}{2} \ln \left(\frac{1 - \varepsilon_t}{\varepsilon_t} \right)$$

Berechnung des Lernkoeffizienten

$$\alpha_t = \frac{1}{2} \ln \left(\frac{1 - \varepsilon_t}{\varepsilon_t} \right)$$

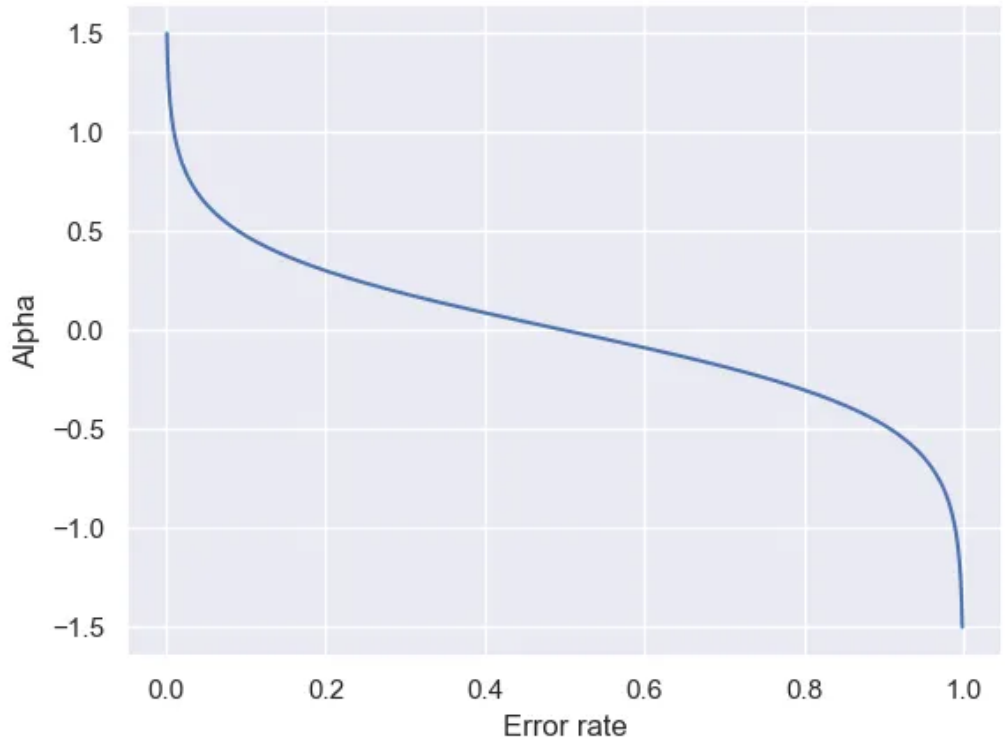

Aktualisierung der Gewichte

- Neue Gewichte der Daten für den nächsten Durchlauf berechnen

$$
\begin{aligned}
w_i^{(t+1)} &= w_i^{(t)} \cdot e^{-\alpha_t} && \text{für korrekt klassifizierte Datenpunke} \\
w_i^{(t+1)} &= w_i^{(t)} \cdot e^{\alpha_t} && \text{für falsch klassifizierte Datenpunke}
\end{aligned}
$$

- Die neuen Gewichte müssen anschließend normalisiert werden, damit ihre Summe wieder 1 ist:

$$
Z_t = \sum_{j=1}^{m} w_i^{(t+1)} \qquad \text{(Normalisierungsfaktor)}
$$

$$
w_i^{(t+1)} = \frac{w_i^{(t+1)}}{Z_t}
$$

Aktualisierung der Gewichte

- Neue Gewichte der Daten für den nächsten Durchlauf berechnen

$$w_i^{(t+1)} = w_i^{(t)} \cdot e^{-\alpha_t} \quad \text{für korrekt klassifizierte Datenpunke}$$
$$w_i^{(t+1)} = w_i^{(t)} \cdot e^{\alpha_t} \quad \text{für falsch klassifizierte Datenpunke}$$

- Die neuen Gewichte müssen anschließend normalisiert werden, damit ihre Summe wieder 1 ist:

$$Z_t = \sum_{j=1}^{m} w_i^{(t+1)} \quad \text{(Normalisierungsfaktor)}$$

$$w_i^{(t+1)} = \frac{w_i^{(t+1)}}{Z_t}$$

Das Ergebnis des Algorithmus

Der Algorithmus gibt ein Gesamtmodell zurück, welches die Klassifizierung des Datenpunktes durch die gewichtete Summe aller schwachen Lerner darstellt:

$$H : X \to \{-1, +1\}$$

$$H(x) = \text{sign}\left(\sum_{t=1}^{T} \alpha_t h_t(x)\right)$$

Der vollständige Algorithmus I

Data: Trainingsdatensatz D, Anzahl der Iterationen T.

Result: Finale Klassifikationsfunktion: $H(x) = \text{sign}\left(\sum_{t=1}^{T} \alpha_t h_t(x)\right)$.

// Initialisiere Gewichte

$w_i^{(1)} = \frac{1}{m}$

for $t = 1$ **to** T **do**

  // Trainiere schwache Lerner

  $(h_j)_{j \in \mathcal{I}} \leftarrow \mathcal{L}(D, w_i^{(t)})$

  // Berechne Fehler

  for $j = 1$ **to** n **do**

    $\varepsilon_j = \sum_{i=1}^{m} w_i^{(t)} \cdot I(y_i \neq h_j(x_i))$

  Wähle Lerner h_j mit minimalem Fehler ε_j als h_t

  // Berechne den Lernerkoeffizienten

  $\alpha_t = \frac{1}{2} \ln\left(\frac{1-\varepsilon_t}{\varepsilon_t}\right)$

  // Algorithmus wird fortgesetzt...

Der vollständige Algorithmus II

// Fortsetzung des Algorithmus
// Weiterhin innerhalb des For-Loops
// Aktualisiere die Gewichte für die nächsten Iterationen

if $y_i = h_t(x_i)$ **then**

$$w_i^{(t+1)} \leftarrow w_i^{(t)} \cdot e^{-\alpha_t}$$

else

$$w_i^{(t+1)} \leftarrow w_i^{(t)} \cdot e^{\alpha_t}$$

// Normalisiere Gewichte

$$Z_t \leftarrow \sum_{j=1}^{m} w_i^{(t+1)}$$

for $i = 1$ **to** m **do**

$$w_i^{(t+1)} \leftarrow \frac{w_i^{(t+1)}}{Z_t}$$

Output: $H(x) = \text{sign}\left(\sum_{t=1}^{T} \alpha_t h_t(x)\right)$

// Ende des Algorithmus

Beispiel

Das XOR-Problem (eine Variation)

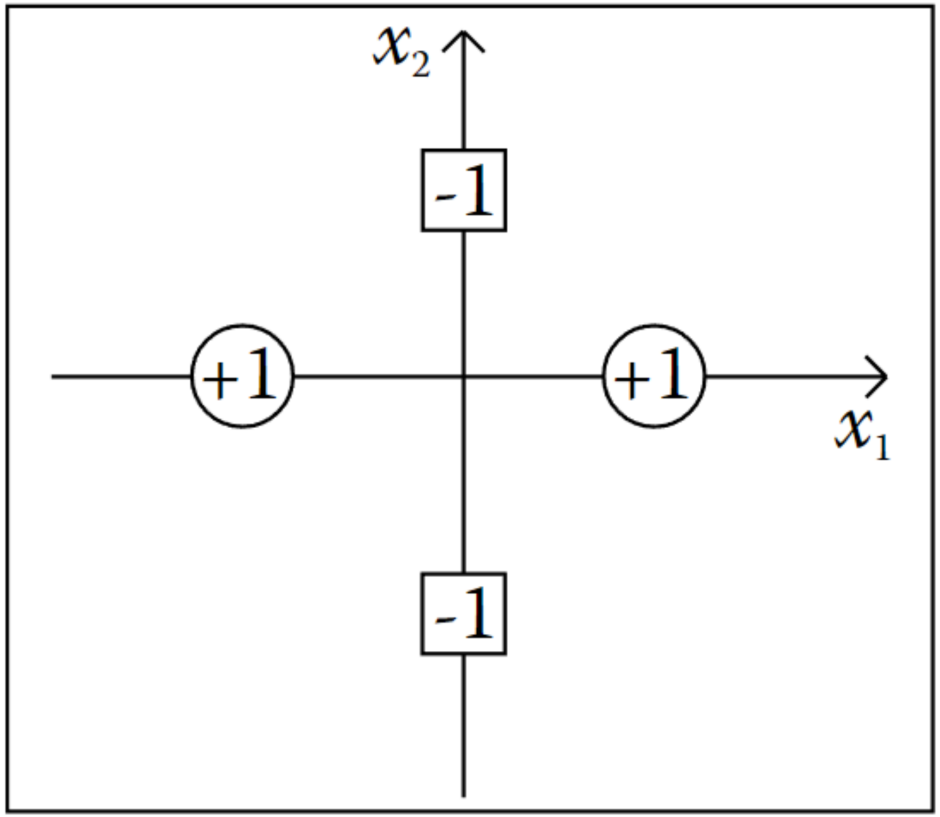

Inhalt

Praktische Anwendung und Beispiele

Bilderkennung und Computervision: Gesichtserkennung

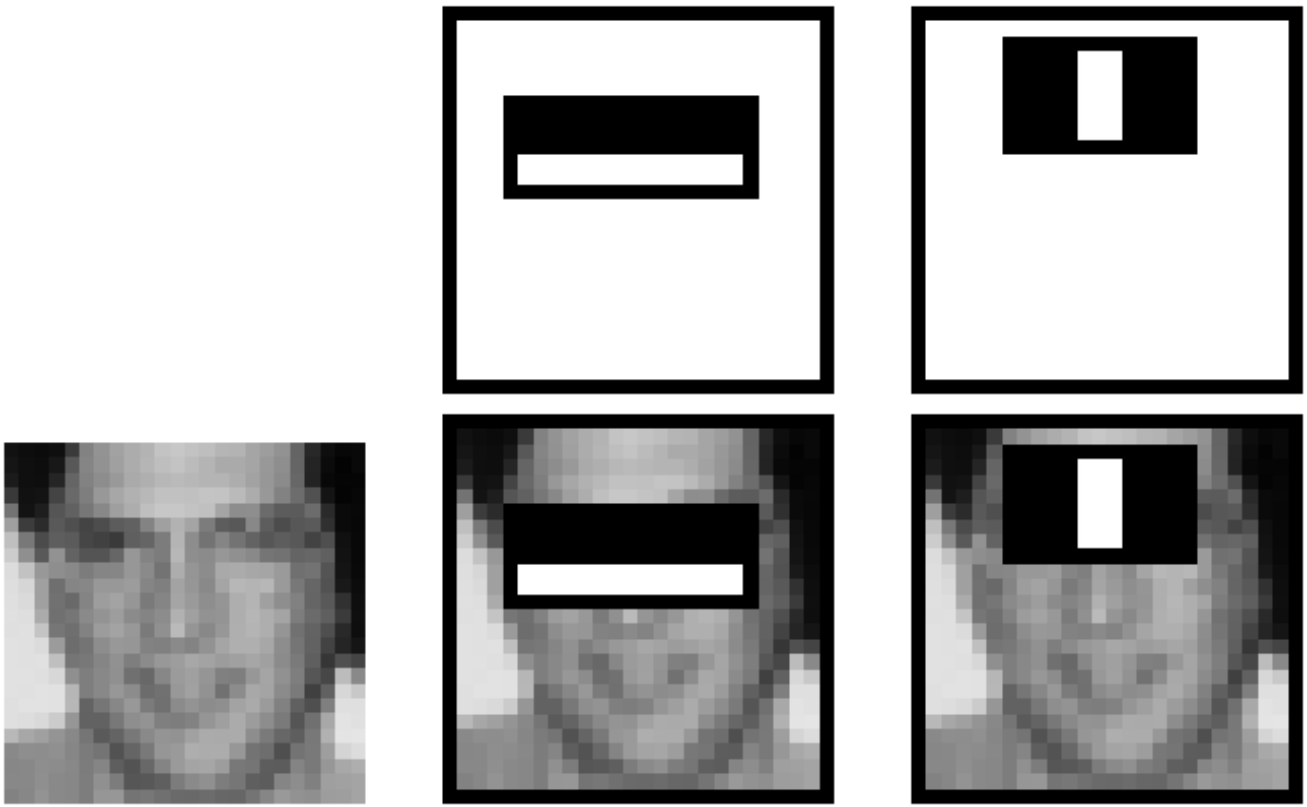

Praktische Anwendung und Beispiele

Textklassifikation und Natural Language Processing: Erkennung von Spam-Mail

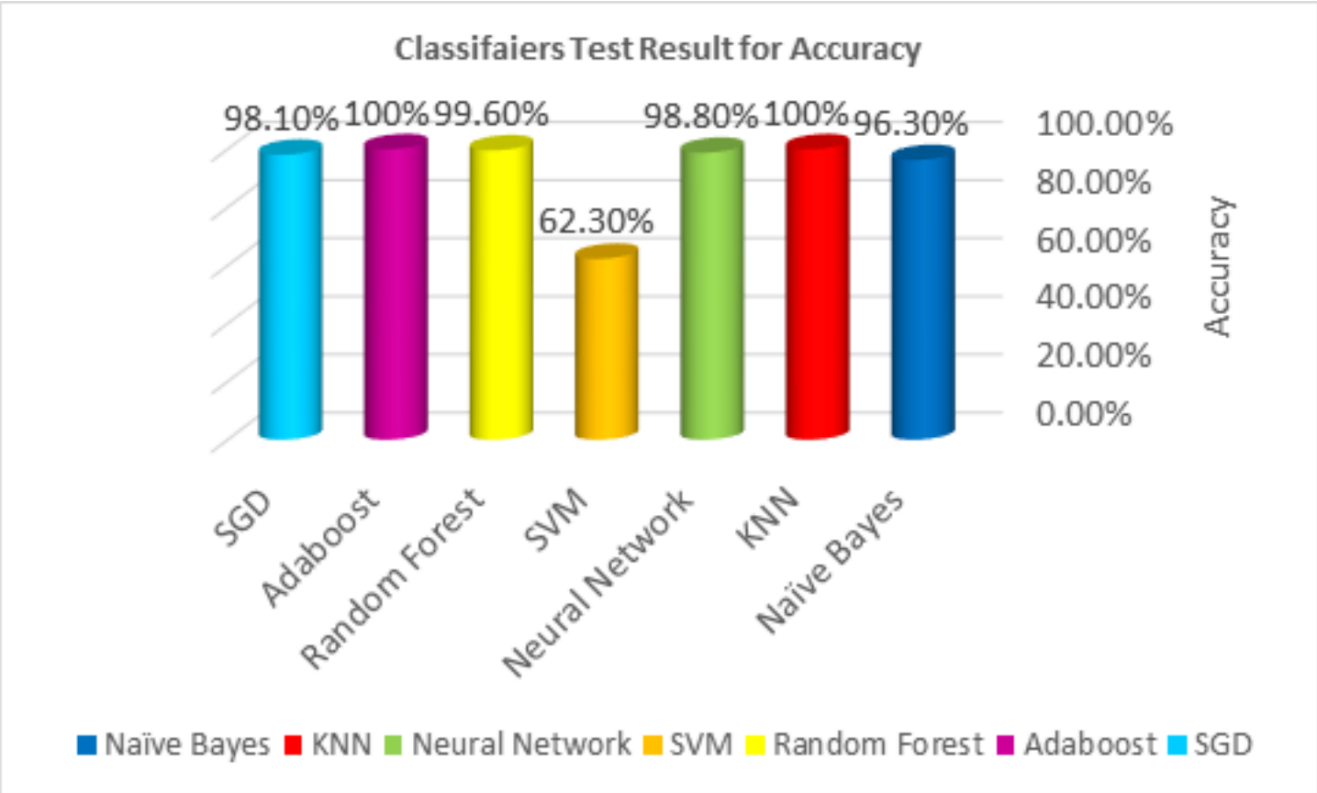

Praktische Anwendung und Beispiele

Medizinische Diagnostik: Risiko/Erkennung von Krankheiten basierend auf Patientendaten

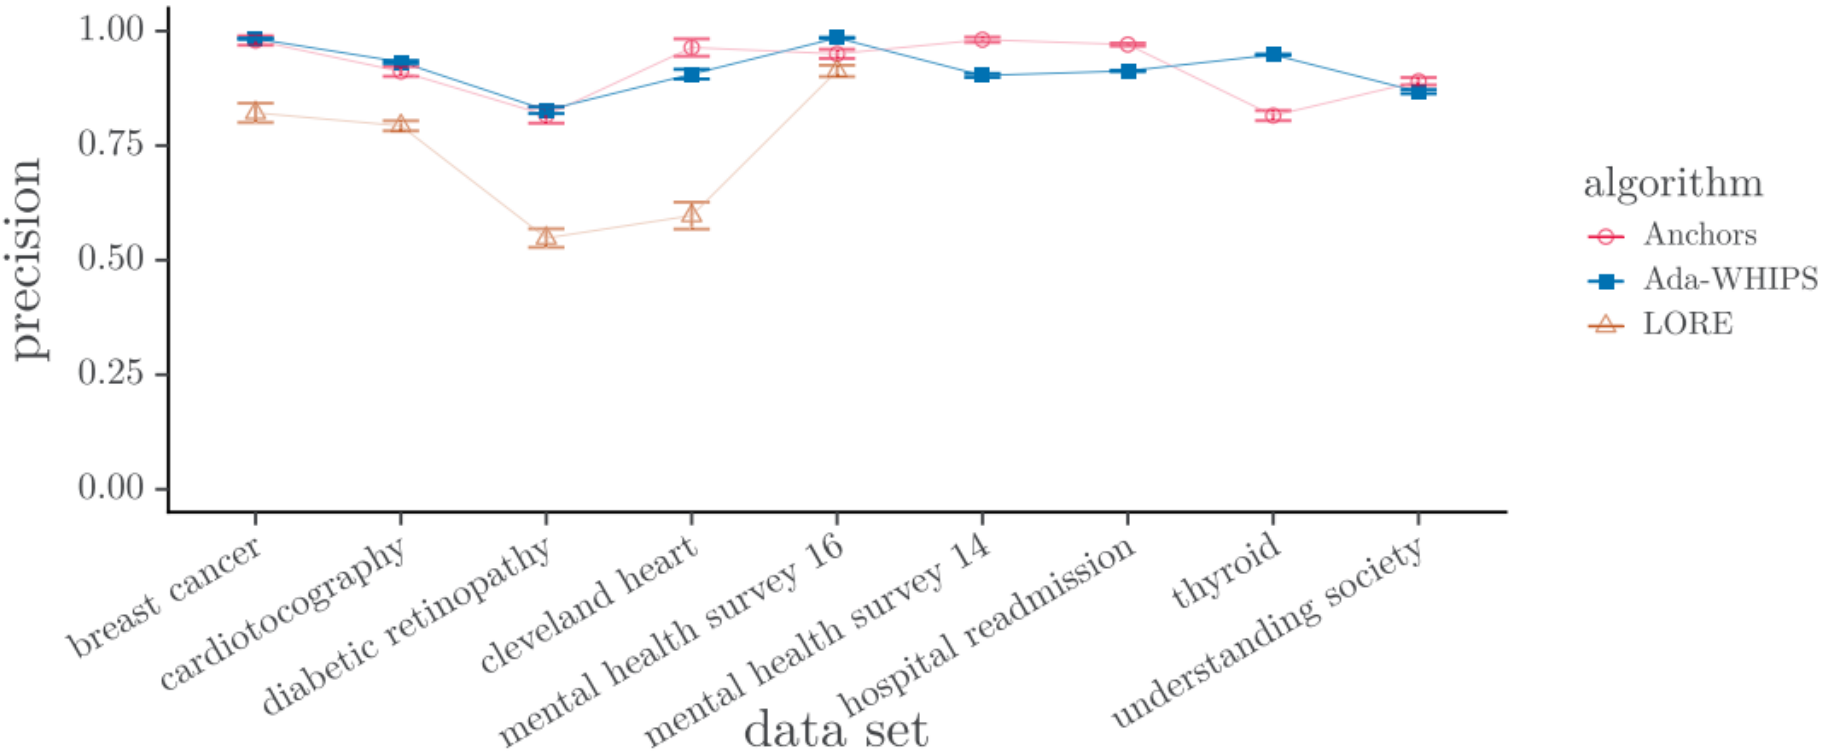

Praktische Anwendung und Beispiele

Finanzwesen: Vorhersage von Aktienkursbewegungen

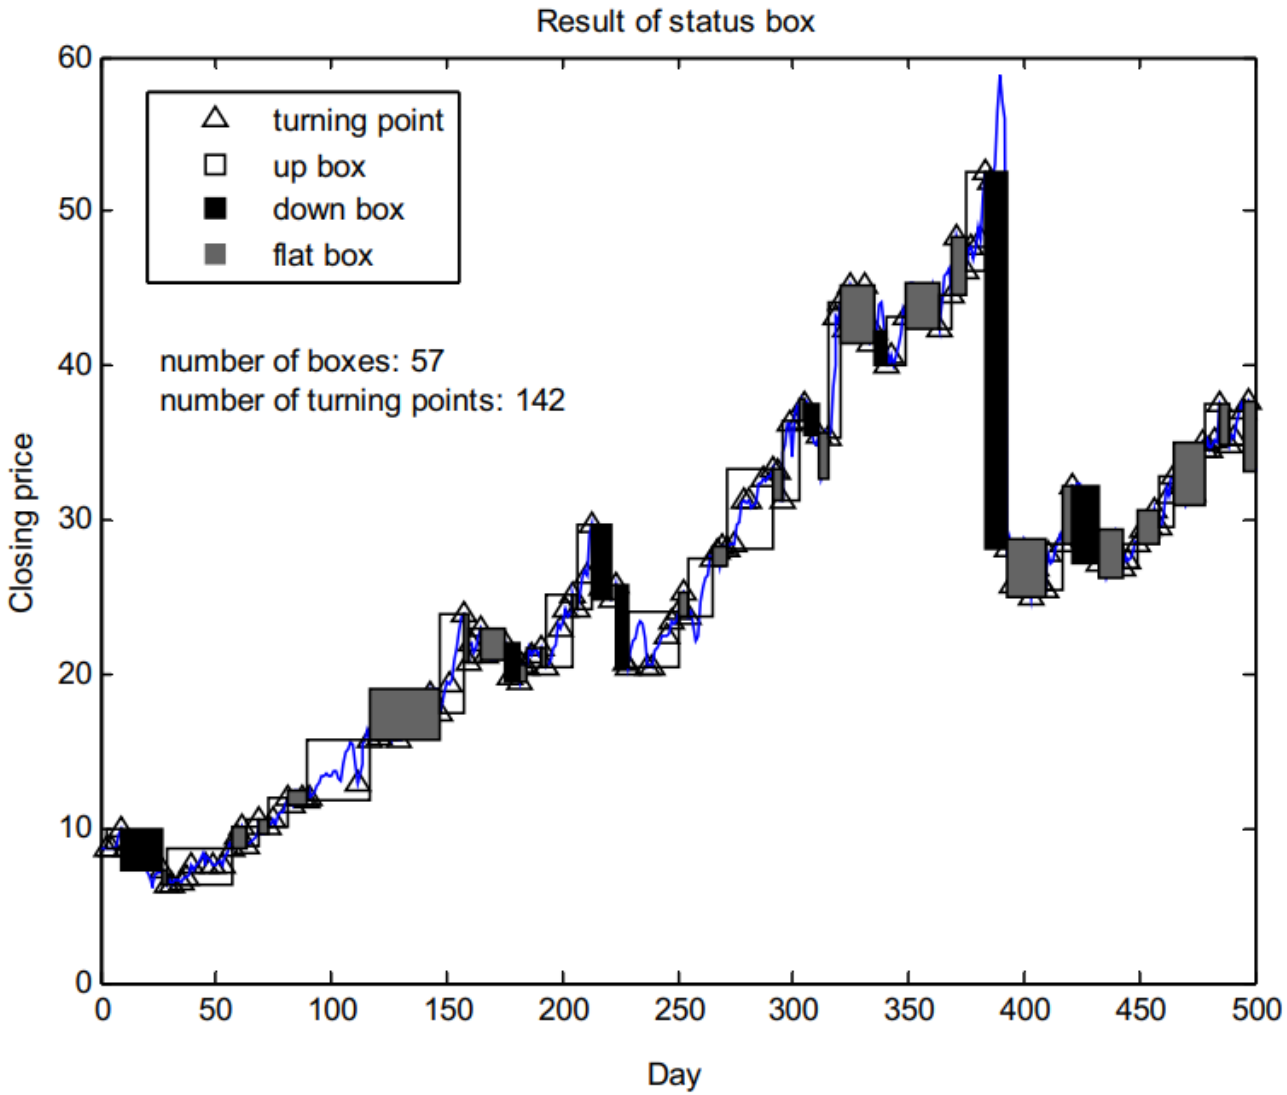

Inhalt

Vor- und Nachteile von AdaBoost

Vorteile:

+ Benutzerfreundlich
+ Flexibel
+ Identifiziert automatisch wichtige Features
+ Neigt weniger zum Overfitting

Nachteile:

- Anfällig für **verrauschte Daten und Ausreißer**
- Training auf großen Datensätzen kann **zeitintensiv** sein
- Hauptsächlich für **binäre Klassifikation** ausgelegt

Vor- und Nachteile von AdaBoost

Vorteile:

+ Benutzerfreundlich
+ Flexibel
+ Identifiziert automatisch wichtige Features
+ Neigt weniger zum Overfitting

Nachteile:

- Anfällig für **verrauschte Daten und Ausreißer**
- Training auf großen Datensätzen kann **zeitintensiv** sein
- Hauptsächlich für **binäre Klassifikation** ausgelegt

Vor- und Nachteile von AdaBoost

Vorteile:

+ Benutzerfreundlich
+ Flexibel
+ Identifiziert automatisch wichtige Features
+ Neigt weniger zum Overfitting

Nachteile:

- Anfällig für **verrauschte Daten und Ausreißer**
- Training auf großen Datensätzen kann **zeitintensiv** sein
- Hauptsächlich für **binäre Klassifikation** ausgelegt

Vor- und Nachteile von AdaBoost

Vorteile:

+ Benutzerfreundlich
+ Flexibel
+ Identifiziert automatisch wichtige Features
+ Neigt weniger zum Overfitting

Nachteile:

- Anfällig für **verrauschte Daten und Ausreißer**
- Training auf großen Datensätzen kann **zeitintensiv** sein
- Hauptsächlich für **binäre Klassifikation** ausgelegt

Vor- und Nachteile von AdaBoost

Vorteile:

+ Benutzerfreundlich
+ Flexibel
+ Identifiziert automatisch wichtige Features
+ Neigt weniger zum Overfitting

Nachteile:

- Anfällig für **verrauschte Daten und Ausreißer**
- Training auf großen Datensätzen kann **zeitintensiv** sein
- Hauptsächlich für **binäre Klassifikation** ausgelegt

Vor- und Nachteile von AdaBoost

Vorteile:

+ Benutzerfreundlich
+ Flexibel
+ Identifiziert automatisch wichtige Features
+ Neigt weniger zum Overfitting

Nachteile:

- Anfällig für **verrauschte Daten und Ausreißer**
- Training auf großen Datensätzen kann **zeitintensiv** sein
- Hauptsächlich für **binäre Klassifikation** ausgelegt

Vor- und Nachteile von AdaBoost

Vorteile:

+ Benutzerfreundlich
+ Flexibel
+ Identifiziert automatisch wichtige Features
+ Neigt weniger zum Overfitting

Nachteile:

- Anfällig für **verrauschte Daten und Ausreißer**
- Training auf großen Datensätzen kann **zeitintensiv** sein
- Hauptsächlich für **binäre Klassifikation** ausgelegt

Vor- und Nachteile von AdaBoost

Vorteile:

+ Benutzerfreundlich
+ Flexibel
+ Identifiziert automatisch wichtige Features
+ Neigt weniger zum Overfitting

Nachteile:

- Anfällig für **verrauschte Daten und Ausreißer**
- Training auf großen Datensätzen kann **zeitintensiv** sein
- Hauptsächlich für **binäre Klassifikation** ausgelegt

Vor- und Nachteile von AdaBoost

Vorteile:

+ Benutzerfreundlich
+ Flexibel
+ Identifiziert automatisch wichtige Features
+ Neigt weniger zum Overfitting

Nachteile:

- Anfällig für **verrauschte Daten und Ausreißer**
- Training auf großen Datensätzen kann **zeitintensiv** sein
- Hauptsächlich für **binäre Klassifikation** ausgelegt

Inhalt

Erweiterungen und Variationen von AdaBoost

- Ursprünglich für binäre Klassifikation entwickelt, durch verschiedene Erweiterungen für diverse Problemstellungen adaptiert
- „AdaBoost.M1“ und „SAMME“ für **Multiklassen-Probleme**
- **Kosten-sensitives** AdaBoost
- Neben Decision Stumps kann AdaBoost mit **SVMs, Neuronalen Netzen und anderen Classifiern** kombiniert werden

Erweiterungen und Variationen von AdaBoost

- Ursprünglich für binäre Klassifikation entwickelt, durch verschiedene Erweiterungen für diverse Problemstellungen adaptiert
- „AdaBoost.M1“ und „SAMME“ für **Multiklassen-Probleme**
- **Kosten-sensitives** AdaBoost
- Neben Decision Stumps kann AdaBoost mit **SVMs, Neuronalen Netzen und anderen Classifiern** kombiniert werden

Erweiterungen und Variationen von AdaBoost

- Ursprünglich für binäre Klassifikation entwickelt, durch verschiedene Erweiterungen für diverse Problemstellungen adaptiert
- „AdaBoost.M1“ und „SAMME“ für **Multiklassen-Probleme**
- **Kosten-sensitives** AdaBoost
- Neben Decision Stumps kann AdaBoost mit **SVMs, Neuronalen Netzen und anderen Classifiern** kombiniert werden

Erweiterungen und Variationen von AdaBoost

- Ursprünglich für binäre Klassifikation entwickelt, durch verschiedene Erweiterungen für diverse Problemstellungen adaptiert
- „AdaBoost.M1“ und „SAMME“ für **Multiklassen-Probleme**
- **Kosten-sensitives** AdaBoost
- Neben Decision Stumps kann AdaBoost mit **SVMs, Neuronalen Netzen und anderen Classifiern** kombiniert werden

Erweiterungen und Variationen von AdaBoost

- **Robuste** Varianten minimieren die Auswirkung von Ausreißern.
- **Online** AdaBoost aktualisiert Modelle ohne Neutrainierung.
- **Direkte Feature Auswahl:** Wählt während des Trainings aus, welche Features wichtig sind und betrachtet nur diese $\rightsquigarrow$ **schnelleres Training**
- Variationen, welche die **Interpretierbarkeit und Erklärbarkeit** verbessern

Erweiterungen und Variationen von AdaBoost

- **Robuste** Varianten minimieren die Auswirkung von Ausreißern.
- **Online** AdaBoost aktualisiert Modelle ohne Neutrainierung.
- **Direkte Feature Auswahl:** Wählt während des Trainings aus, welche Features wichtig sind und betrachtet nur diese $\rightsquigarrow$ **schnelleres Training**
- Variationen, welche die **Interpretierbarkeit und Erklärbarkeit** verbessern

Erweiterungen und Variationen von AdaBoost

- **Robuste** Varianten minimieren die Auswirkung von Ausreißern.
- **Online** AdaBoost aktualisiert Modelle ohne Neutrainierung.
- **Direkte Feature Auswahl:** Wählt während des Trainings aus, welche Features wichtig sind und betrachtet nur diese $\rightsquigarrow$ **schnelleres Training**
- Variationen, welche die **Interpretierbarkeit und Erklärbarkeit** verbessern

Erweiterungen und Variationen von AdaBoost

- **Robuste** Varianten minimieren die Auswirkung von Ausreißern.
- **Online** AdaBoost aktualisiert Modelle ohne Neutrainierung.
- **Direkte Feature Auswahl:** Wählt während des Trainings aus, welche Features wichtig sind und betrachtet nur diese $\rightsquigarrow$ **schnelleres Training**
- Variationen, welche die **Interpretierbarkeit und Erklärbarkeit** verbessern

Inhalt

Literatur I

Julian Hatwell, Mohamed Medhat Gaber, and R Muhammad Atif Azad.
Ada-WHIPS: explaining AdaBoost classification with applications in the health sciences.
BMC Medical Informatics and Decision Making, 20(1):1–25, 2020.

Weiming Hu, Jun Gao, Yanguo Wang, Ou Wu, and Stephen Maybank.
Online adaboost-based parameterized methods for dynamic distributed network intrusion detection.
IEEE Transactions on Cybernetics, 44(1):66–82, 2013.

Trevor Hastie, Saharon Rosset, Ji Zhu, and Hui Zou.
Multi-class adaboost.
Statistics and its Interface, 2(3):349–360, 2009.

Literatur II


Hamed Masnadi-Shirazi and Nuno Vasconcelos.
Cost-sensitive boosting.
IEEE Transactions on pattern analysis and machine intelligence, 33(2):294–309, 2010.


Manish Panwar, Jayesh Rajesh Jogi, Mahesh Vijay Mankar, Mohamed Alhassan, and Shreyas Kulkarni.
Detection of Spam Email.
AJISE, 1, 2022.


Paul Viola and Michael Jones.
Fast and robust classification using asymmetric adaboost and a detector cascade.
Advances in neural information processing systems, 14, 2001.

Literatur III

Paul Viola and Michael Jones.
Rapid object detection using a boosted cascade of simple features.
In *Proceedings of the 2001 IEEE Computer Society Conference on Computer Vision and Pattern Recognition. CVPR 2001*. IEEE, 2001.

Xindong Wu and Vipin Kumar.
The Top Ten Algorithms in Data Mining.
CRC press, 2009.

Jianxin Wu, James M Rehg, and Matthew Mullin.
Learning a rare event detection cascade by direct feature selection.
Advances in Neural Information Processing Systems, 16, 2003.

Literatur IV


Xiao-dan Zhang, Ang Li, and Ran Pan.
Stock trend prediction based on a new status box method and AdaBoost probabilistic support vector machine.
Applied Soft Computing, 49:385–398, 2016.

Zusatzmaterial

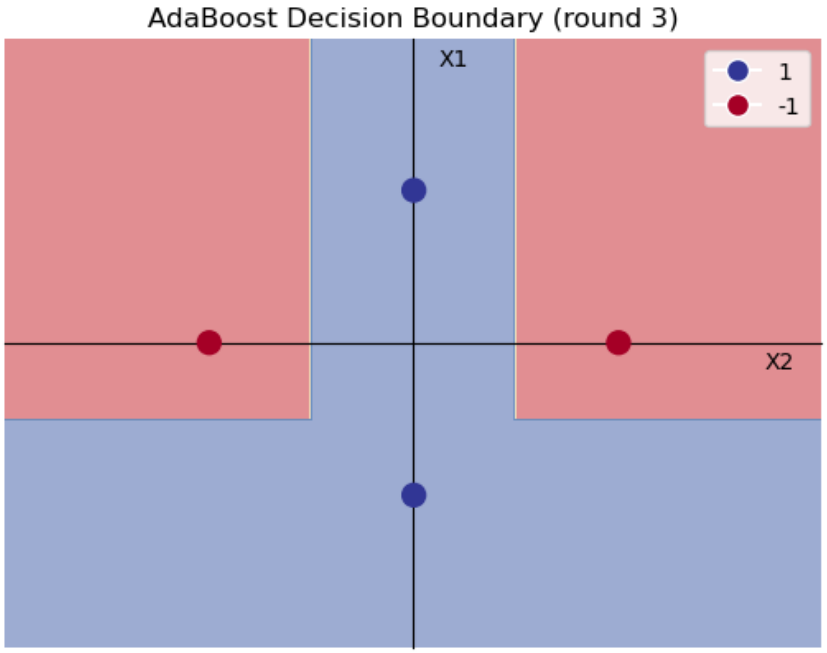

Umsetzungen und Beispiele von AdaBoost + diese Präsentation mit Ausarbeitung in LaTeX auf *GitHub*.

Danke

Vielen Dank für die Aufmerksamkeit!